

PUC CAMPINAS

Pontifícia Universidade Católica de Campinas
Escola Politécnica

Coleta e Tratamento de Dados

Análise e Visualização de Dados

Fernando H Carvalho Silva
E-mail: fernando.henrique@puc-campinas.edu.br

PUC CAMPINAS

Agosto de 2025

Coleta de Dados

- Responsável pela aquisição dos dados por meio de um dispositivo ou sensor.
- Provavelmente a etapa mais custosa.
- Grandes volumes de dados tem sido coletados, armazenados e transmitidos.
- Diferentes equipamentos de aquisição.
- Domínio da aplicação.
- Natureza dos dados: sinal, texto, imagem, vídeo, áudio.
- Quantas amostras são suficientes.?

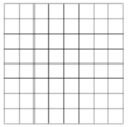
Coleta de Dados

- Processo de amostragem de sinais que mede condições físicas de um fenômeno e converte as amostras resultantes em valores digitais que podem ser manipulados por um computador.
- Com o crescente avanço tecnológico e a demanda de determinadas áreas de aplicação, os dispositivos tem evoluído significativamente nas últimas décadas.
- Os parâmetros de funcionalidade e o desempenho dos dispositivos são dependentes, em grande parte, das áreas que os utilizam.
- Os dispositivos de aquisição podem apresentar características bem diferentes em termos de resolução, velocidade de operação, precisão e custo.

Coleta de Dados

Exemplos: Imagens X Vídeos

- Uma imagem colorida de 1024 X 1024 pixels, cada pixel representado por 24 bits, requer 3 MBytes para seu armazenamento sem compressão.
- Um vídeo com duração de 1 minuto, formado por imagens de 512 ˆ 512 pixels, exibidas a uma taxa de 30 imagens por segundo, cada pixel representado por 24 bits, requer aproximadamente 1.4 GBytes para seu armazenamento.
- Suponha um canal de comunicação com taxa de transmissão igual a 64000 bits/segundo. Aproximadamente 7 minutos seriam necessários para a transmissão de uma imagem com dimensões 1024 X 1024 pixels, 24 bits para cada pixel.



imagem



vídeo

Coleta de Dados

Exemplos de dispositivos de aquisição de dados:

- Câmeras fotográficas
- Câmeras de vídeo
- Tomógrafos médicos
- Satélites
- Acelerômetros
- Giroscópios
- Barômetros
- Sensores de localização
- Telefones celulares
- Digitalizadores
- Microfones
- Sismógrafos
- Medidores de Pressão Arterial
- Monitores de batimento cardíaco
- Telescópios
- Microscópios

Tratamento dos Dados

Leitura dos Arquivos:

- HTML
- XML
- JSON
- CSV
- JPG, PNG, TIFF, GIF, BMP
- MPEG-4, AVI, MOV, WMV
- WAV, MPEG-3, WMA, OGG, FLAC
- **Dados:** coleção de amostras, entidades, objetos, instâncias.
- **Atributos:** propriedades ou características das amostras.
    - Exemplo: temperatura, preço, cor, área, altura**.**
- **Valores de atributos:** números ou símbolos assinalados a um atributo

Tratamento dos Dados

Forma comum de representação de dados:

$$\mathbf{D} = \left[\begin{array}{c|cccc} & X_1 & X_2 & \dots & X_d \\ \hline \mathbf{x}_1 & x_{11} & x_{12} & \dots & x_{1d} \\ \mathbf{x}_2 & x_{21} & x_{12} & \dots & x_{2d} \\ \vdots & \vdots & \vdots & \ddots & \vdots \\ \mathbf{x}_n & x_{n1} & x_{n2} & \dots & x_{nd} \end{array}\right]$$

Tratamento dos Dados

Dependendo do domínio da aplicação:

Linhas são chamadas de:

- Entidades
- Instâncias
- Exemplos
- Registros
- Transações

Colunas são chamadas de:

- Atributos
- Propriedades
- Características
- Dimensões
- Campos

Exemplo: Base de dados Iris.

Essa base contém dados multivariados apresentados pelo estatístico e biólogo inglês Ronald Fischer em 1936.



Iris setosa



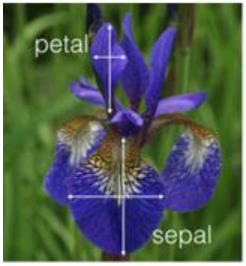
Iris versicolor



Iris virginica

Tratamento dos Dados

- A base de dados consiste em 150 amostras, sendo 50 amostras de cada uma das três espécies da flor Íris (Iris setosa, Iris Virginica e Iris versicolor).
- Quatro atributos foram medidos de cada amostra: comprimento e largura (em centímetros) das sépalas e pétalas.
- Dados disponíveis em: https://archive.ics.uci.edu/ml/datasets/iris



Exemplo de amostra da base:

$\mathbf{D} =$

	Comprimento da Sépala X_1	Largura da Sépala X_2	Comprimento da Pétala X_3	Largura da Pétala X_4	Classe Y
$\mathbf{x}_1$	5.9	3.1	4.2	1.5	Iris-versicolor
$\mathbf{x}_2$	6.9	3.9	4.9	1.5	Iris-versicolor
$\mathbf{x}_3$	6.6	2.2	4.6	1.3	Iris-versicolor
$\mathbf{x}_4$	4.6	3.2	1.4	0.2	Iris-setosa
$\mathbf{x}_5$	6.0	2.2	4.0	1.0	Iris-versicolor
⋮	⋮	⋮	⋮	⋮	⋮
$\mathbf{x}_{149}$	Tratamento dos Dados		6.7	2.2	Iris-virginica
$\mathbf{x}_{150}$	5.1	3.4	1.5	0.2	Iris-setosa

Tratamento dos Dados – Dados Faltantes

Qualidade dos dados: a coleta dos dados é suscetível a anomalias, erros ou inconsistências.

Dados faltantes

- Ausência de observações resultantes de perda de informação.
- Indisponibilidade durante a coleta.
- Falha humana ou no dispositivo.
- Valores incompletos, atributos incompletos.
- Atributo pode não ser aplicável a todos os casos (por exemplo, salário anual não é aplicável a crianças).

Exemplo: ocupação = “ “.

Tratamento dos Dados – Dados faltantes

Potencial Problema

- Quantidade de dados menor do que a esperada pode comprometer a confiabilidade dos resultados da análise, eventualmente produzindo resultados tendenciosos para uma determinada população

Possíveis soluções:

- Estimar dados ou valores faltantes.
- Ignorar valores faltantes durante a análise.
- Preencher com medidas estatísticas (média, mediana ou moda)

Tratamento dos Dados – Dados discrepantes

Dados discrepantes

- Ruídos: Modificação ou distorção de valores originais
- Outliers: dados com valores consideravelmente diferentes da maioria dos demais no conjunto de dados.
- Erros de resposta.
- Sensores defeituosos
- Problema no processo de coleta, entrada ou transmissão de dados.

Exemplo: idade = -10.

Tratamento dos Dados – Dados discrepantes

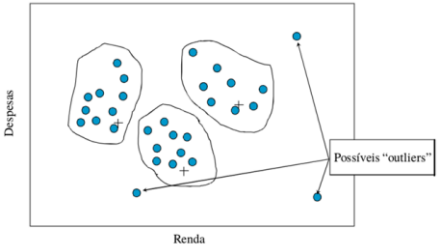
Potencial problema:

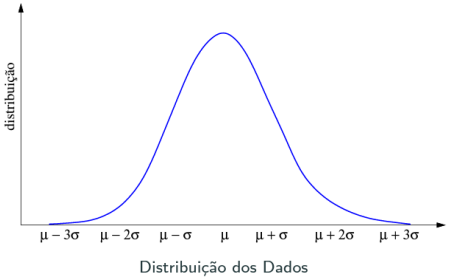
- Valores resultantes podem ser subestimados ou superestimados.

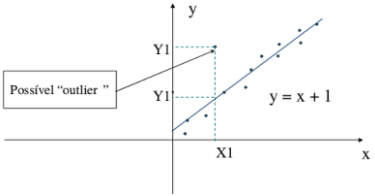
Possível soluções

- Excluir casos.
- Substituir os valores errôneos.

Tratamento dos Dados – Dados discrepantes







Tratamento dos Dados – Valores Repetidos

Valores repetidos

- Dados duplicados ou que são quase duplicatas de outros.
- Podem ser gerados quando fontes heterogêneas de dado são unidas.
- Falha de atualização da fonte de dados.

Exemplo: mesma pessoa com múltiplos endereços de email

Tratamento dos Dados – Valores Repetidos

Potenciais Problemas

- Aumento do custo computacional e comprometimento dos resultados (causado ao estimar as distribuições de probabilidades) se muitas amostras forem utilizadas no treinamento.

Possíveis Soluções

- Excluir duplicatas.
- Aplicar técnicas de seleção de características ou redução de dados.

Redução dos dados

É intuitivo pensar que, quanto maior a quantidade de objetos e atributos, mais informações estão disponíveis para o processo de análise. Entretanto, o aumento do número de objetos e do número de atributos pode fazer com que os dados disponíveis se tornem esparsos ou tornar o processamento muito complexo.

Algumas técnicas de redução de dados são:

- Seleção de atributos ou características;
- Redução do número de dados.

Redução dos dados – Seleção de atributos

- Atributos irrelevantes, pouco relevantes ou redundantes são detectados e removidos.
- Atributos com valores constantes para todos os dados ou que variam pouco (variância baixa) são candidatos à remoção.

Redução dos dados – Redução do número de dados

- Pode afetar tanto os atributos quantos os objetos, ou seja, a redução pode ser realizada tanto na quantidade de objetos quanto na dimensionalidade dos objetos da base.
- Amostragem: técnica estatística para selecionar um subconjunto de objetos de uma base que seja representativo de toda ela para efeitos de análise.

Amostragem

- Obter um conjunto completo dos dados de interesse é muito caro ou consome tempo demais.
- Princípio básico: amostras representativas podem funcionar tão bem quanto o conjunto completo.
- Amostras são representativas se elas tem aproximadamente as mesmas propriedades que o conjunto original de dados.

Amostragem aleatória simples

Nessa forma de amostragem, os indivíduos de uma população têm uma chance igual ou maior que zero de serem selecionados para a compor a amostra. Ela é chamada de amostra aleatória simples pois, a seleção de elementos é feita em forma de sorteio, dessa forma, não há critério ou filtro no processo de amostragem.



Amostragem sistemática

Na amostra sistemática os elementos do universo a ser pesquisado são divididos em grupos numericamente iguais, assim, após essa segmentação é definido um "ponto de partida", de modo a estabelecer um número que se repetirá, em sequência, dentro de todos os grupos determinados, até que toda a amostragem seja selecionada.



Amostragem estratificada

A amostra estratificada é uma técnica de amostra probabilística que é realizada em duas etapas. Esse tipo de amostragem separa a população em grupos e subgrupos, buscando assim, uma amostra mais representativa.

Para realizar uma amostra estratificada apenas dois passos são necessários. Primeiro, deve-se dividir a população em grupos distintos. Esses grupos devem ser segmentados com características da população que auxiliem o tema estudado, podendo ser idade, sexo, trabalho, nível de escolaridade, entre outros.

Depois de distribuir a população nesses grupos, são utilizadas outras formas para eleger os entrevistados dentro de cada grupo, podendo adotar critérios aleatórios ou não. Assim, para selecionar uma amostra de forma não enviesada podemos utilizar a amostra aleatória simples ou sistemática.

Amostragem por conglomerados

Diferente das amostras probabilísticas anteriormente apresentadas, que selecionam primeiro o indivíduo, a amostra por conglomerados tem como fase inicial a seleção de um grupo (cidade ou estado em um país) para compor a amostragem.



Amostragem por cotas

A amostra por cotas, é uma forma de amostragem muito utilizada em pesquisas de mercado, eleitorais e de opinião pública. Ela é uma amostra que, por meio de cotas, seleciona proporcionalmente pessoas com semelhantes características de uma população.

Tratamento dos Dados – Amostragem

Uma amostra deve ter as mesmas características da população da qual foi retirada. Para a obtenção de uma amostra, é preciso que a coleta de dados siga uma estratégia preestabelecida.
Em muitos casos a qualidade dos dados é mais importante do que a quantidade. Quando uma amostra não representa a população que deveria representar, temos um **viés de amostragem.**

Existem vários tipos de viés de amostragem:

- **Viés de autosseleção:** ocorre quando a amostra é selecionada por motivações próprias.
- **Viés estatístico:** ocorre quando os dados possuem erros sistemáticos de medição ou amostragem produzidos pelo processo utilizado.
- **Viés de seleção:** quando se escolhe os dados de forma seletiva, consciente ou inconscientemente.

Para que o viés seja reduzido, é preciso que as amostras sejam obtidas de forma cuidadosa.

Tratamento dos Dados

Além dos problemas de inconsistência, mencionados anteriormente, que as bases de dados podem sofrer, outro tipo comum é a não uniformidade dos atributos, ou seja, alguns atributos podem ser numéricos, outros categóricos, bem como os domínios de cada atributo podem ser muito diferentes.

Essas situações podem afetar significativamente o processo de análise de dados, tal que elas precisam ser tratadas antes da sua aplicação.

Principais técnicas: padronização e normalização.

Tratamento dos Dados - Padronização

Padronização: visa resolver problemas de unidades e escalas dos dados.

- **Capitalização:** dados nominais podem aparecer em minúsculo, maiúsculo ou ambos. Para evitar inconsistências como ferramentas sensíveis a letras minúsculas ou maiúsculas, pode-se padronizar as fontes em uma das formas.

- **Caracteres especiais:** alguns processos são sensíveis ao conjunto de caracteres (por exemplo, problemas em decorrência de acentuação) utilizado em determinado idioma. Uma simples troca de letras em valores nominais pode evitar eventuais problemas.

Padronização: visa resolver problemas de unidades e escalas dos dados.

- **Padronização de formatos:** uso de alguns tipos de atributos (datas, números de documentos) permite diferentes formatos. Por exemplo, datas podem ser apresentadas como DDMMAAAA ou MMDDAAAA. Para evitar esses problemas, pode-se padronizar o formato de cada atributo da base, especialmente quando diferentes bases são integradas.
- **Conversão de unidades:** uso de diferentes unidades de medida, por exemplo, centímetros ou metros, quilômetros por hora ou milhas por hora. Como anteriormente, os dados devem ser convertidos e padronizados em uma mesma unidade de medida.

Normalização

- Procura tornar os dados mais apropriados à aplicação de alguma técnica de análise.
- Algumas técnicas: normalização min-máx, normalização z-score; normalização max-abs; normalização robusta; normalização por escala decimal.

Tratamento dos Dados - Normalização

- Normalização min-max: $v' = \dfrac{v - \min}{\max - \min}$
- Normalização z-score: $v' = \dfrac{v - \mu}{\sigma}$
- Normalização max-abs: $v' = \dfrac{v}{\max(\text{abs})}$
- Normalização robusta: $v' = \dfrac{v - \text{mediana}}{Q_3 - Q_1}$

  em que Q_1 e Q_3 são o primeiro e o terceiro quartis.
- Normalização por escala decimal: $v' = \dfrac{v}{10^j}$

  em que j é menor inteiro tal que $\max(|v'|) < 1$

Tratamento dos Dados – Normalização Min-Máx

CPF	Despesa
99999999999	1000
11111111111	2000
22222222222	3000
33333333333	4000
44444444444	5000

$$v_1' = \frac{1000 - 1000}{5000 - 1000} = 0$$

$$v_2' = \frac{2000 - 1000}{5000 - 1000} = 0.25$$

$$v_3' = \frac{3000 - 1000}{5000 - 1000} = 0.5$$

$$v_4' = \frac{4000 - 1000}{5000 - 1000} = 0.75$$

$$v_5' = \frac{5000 - 1000}{5000 - 1000} = 1$$

CPF	Despesa
99999999999	0
11111111111	0.25
22222222222	0.5
33333333333	0.75
44444444444	1

Desbalanceamento de classes:

- Situação ocorre quando as classes não estão igualmente representadas.

- Exemplos:
- 1) Classificação Binária: em um problema de detecção de fraudes em transações de cartão de crédito, 99% das amostras pertencem à classe negativa (não fraude) e 1% das amostras pertencem à classe positiva (fraude).
- 2) Classificação multiclasse: dados de treinamento de três classes, em que 70% da amostras são da classe A, 25% da classe B e 5% da classe C.

Desbalanceamento de classes

Potencial Problema: Análise será tendenciosa para a classe majoritária.

Possíveis soluções:

1) coletar mais dados (nem sempre é possível);
2) Balancear a base de dados;

Exercícios

1) Estimar o tamanho de uma imagem na escala de cinza de 800x800 pixels, sendo que cada pixels será representado por 8 bits.
2) Normalize utilizando a estratégia de Min-Máx os valores abaixo:

32	29	25	66	40	18	66	42	39	58

Exercícios

Unidades de Medida da Informática		
Unidade	**Símbolo**	**Valor**
Bit	b	
Byte	B	8 bits
Kilobyte	KB	1024 Bytes
Megabyte	MB	1024 Kilobytes
Gigabyte	GB	1024 Megabytes
Terabyte	TB	1024 Gigabytes
Petabyte	PB	1024 Terabytes
Exabyte	EB	1024 Petabytes
Zettabyte	ZB	1024 Exabytes
Yottabyte	YB	1024 Zettabytes