Inteligência Artificial

Agrupamento Hierárquico

Prof.

Fernando H. C. Silva

fernando.henrique@puc-campinas.edu.br

Sumário

1 Agrupamento Hierárquico

2 Linkage Family

3 Comparação e Exercício

4 Bisecting K-Means

Agrupamento Hierárquico

1 Agrupamento Hierárquico

2 Linkage Family

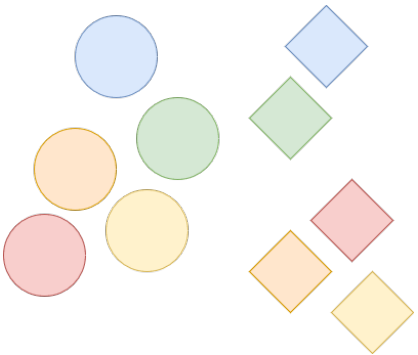
3 Comparação e Exercício

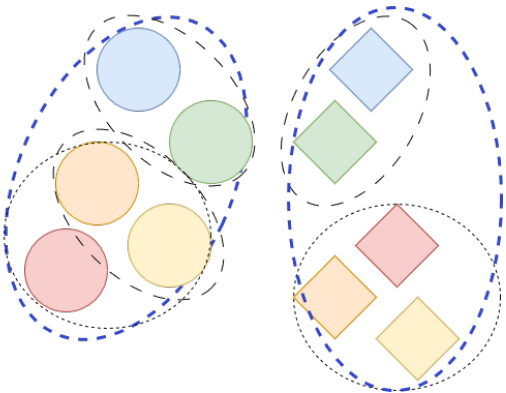
4 Bisecting K-Means

Motivação

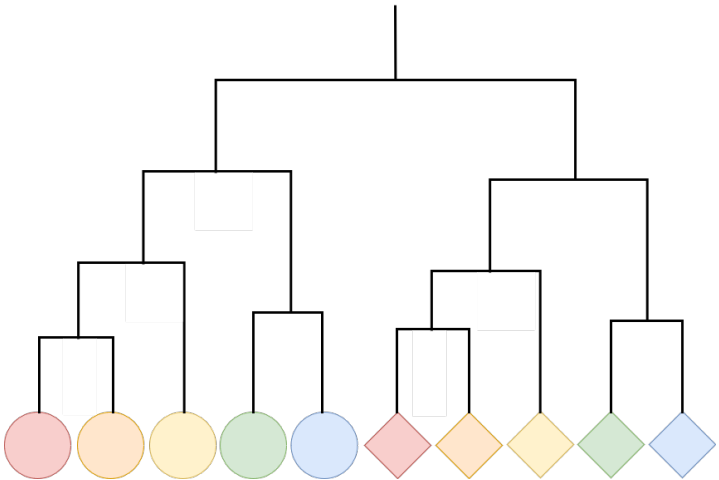
- Muitas vezes temos várias maneiras de agrupar os dados
- Mais que isso, como podemos analisar grupos e subgrupos?

Motivação





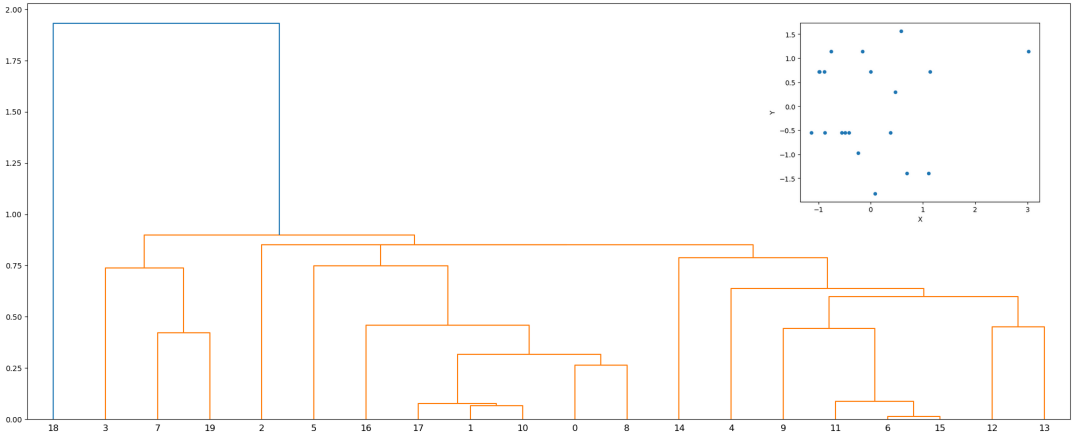
Motivação - Hierarquia de Grupos (dendrograma)



Vantagens

- Visualização, pois o dendrograma será em duas dimensões
- Detecção de *outliers*, pois ficarão evidentes nas hierarquias
- Não é necessário conhecer a quantidade de grupos *apriori*

Outlier


2.00
1.75
1.50
1.25
1.00
0.75
0.50
0.25
0.00
18 3 7 19 2 5 16 17 1 10 0 8 14 4 9 11 6 15 12 13
1.5
1.0
0.5
0.0
−0.5
−1.0
−1.5
Y
−1 0 1 2 3
X

Hierarquias de Partições

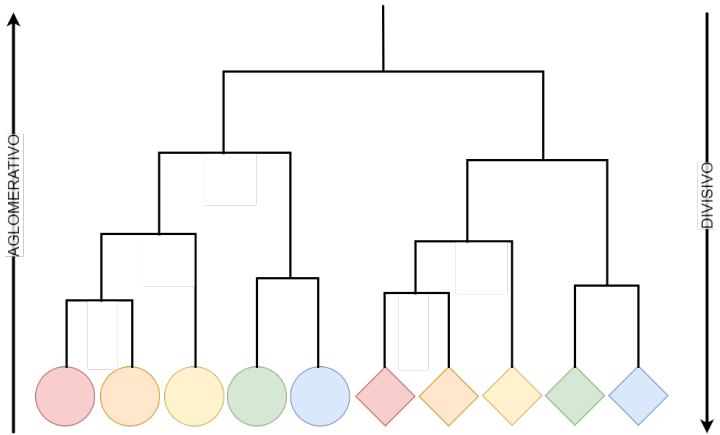
- Consideraremos sempre que as partições maiores englobam completamente partições menores
- Ou seja, as partições estão sempre aninhadas
- e.g. $P_1 = \{(x_1, x_2, x_3), (x_4, x_5, x_6)\}$ e $P_2 = \{(x_1, x_2, x_3), (x_4, x_5), (x_6)\}$; Todos os grupos em P2 são sub-grupos de P1

Aglomerativo e Divisivo

Temos duas abordagens para gerar hierarquias de grupos

- Aglomerativo: ou *bottom-up*, onde começamos com um grupo para cada amostra e vamos juntando grupos até termos um único grupo
- Divisivo: ou *top-down*, onde começamos com um único grupo com todas as amostras e vamos dividindo esse grupo até termos grupos unitários (ou *singletons*)

Aglomerativo versus Divisivo



Discussão

- Mas como decidir quando juntar grupos e amostras?
- Qual prioridade ou ordem deve ser seguida?
- Veremos algoritmos aglomerativos e um divisivo para reponder a essas questões

Linkage Family

1 Agrupamento Hierárquico

2 Linkage Family

3 Comparação e Exercício

4 Bisecting K-Means

Ideia Geral

- Existe uma família de algoritmos de agrupamento hierárquico, chamada linkage
- São algoritmos aglomerativos
- Definiremos a distância entre dois grupos de várias formas, dependendo do algoritmo escolhido

Linkage Family

Temos 3 principais algoritmos na família Linkage:

- Single-linkage: a distância entre grupos é dada pela menor distância entre amostras dos grupos. Outra forma de pensar é que a distância é dada pela distância que permita um **único** par de amostras de se 'encontrar'
- Complete-linkage: a distância entre grupos é dada pela maior distância entre amostras dos grupos. Outra forma de pensar é que a distância é dada pela distância que permita que todo e qualquer par de amostras entre os grupos se 'encontrem'
- Average-linkage: a distância entre grupos é dada pela distância média entre amostras dos grupos. Outra forma de pensar é um meio termo entre complete e single linkages

Funcionamento

- Enquanto tiver mais de um grupo: De forma gulosa ligue os dois grupos com menor distância
- é isso!

Funcionamento

- Enquanto tiver mais de um grupo: De forma gulosa ligue os dois grupos com menor distância
- O cálculo da distância entre grupo dependerá do tipo de linkage escolhido
- E lembrem-se que no começo cada grupo é uma única amostra, mas é um grupo

Apenas distâncias

- Notem que essa família de algoritmos não precisa da informação da distribuição dos pontos (como o *k-means* precisava)
- Mas opera apenas com as distâncias relativas entre as amostras
- Precisamos normalizar a base de dados?

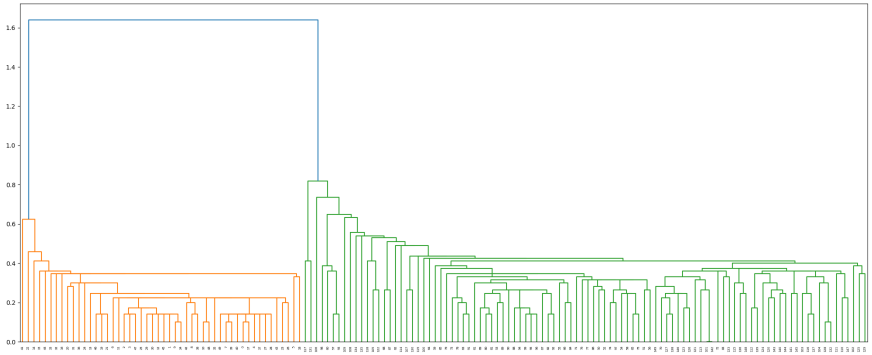
Chainning Effect

- Como esse algoritmo vai se comportar se tivermos 2 grupos bem definidos ligados por uma ponte?

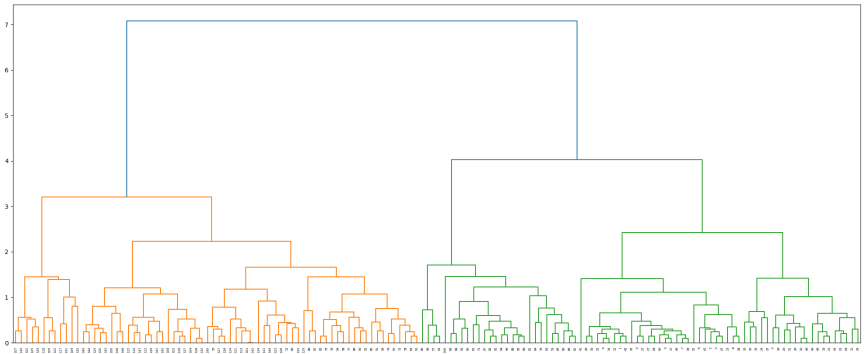
Linkage Effect

- Como esse algoritmo vai se comportar se tivermos 2 grupos bem definidos ligados por uma ponte?
- O single-linkage ou complete-linkage é mais sensível a esse problema?

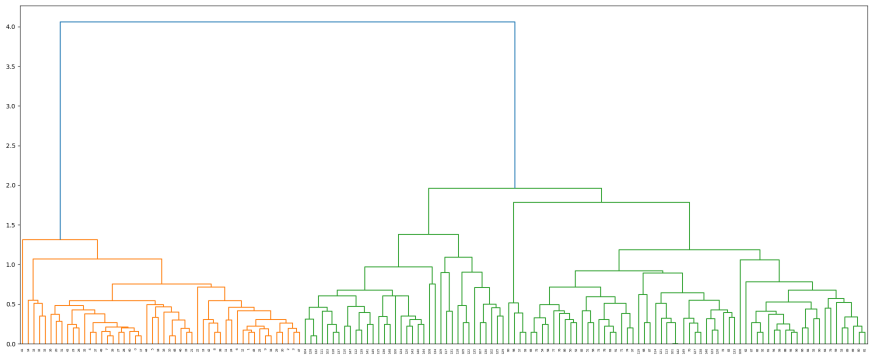
Single-linkage Iris



Complete-linkage Iris



Average-linkage Iris



Comparação e Exercício

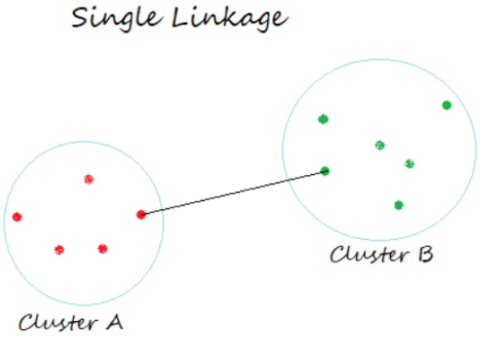
1 Agrupamento Hierárquico

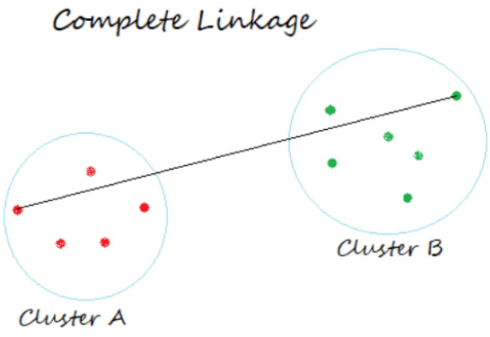
2 Linkage Family

3 Comparação e Exercício

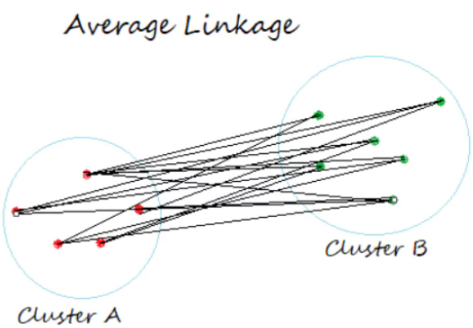
4 Bisecting K-Means

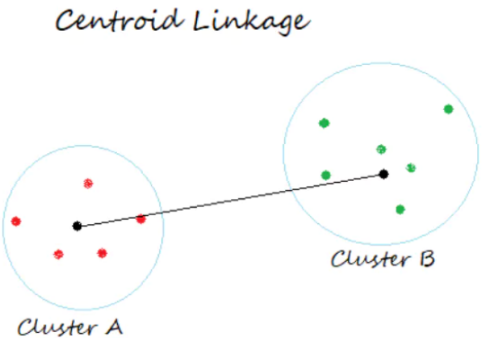
Comparação


Single Linkage
Cluster A
Cluster B


Complete Linkage
Cluster A
Cluster B

Comparação


Average Linkage
Cluster B
Cluster A

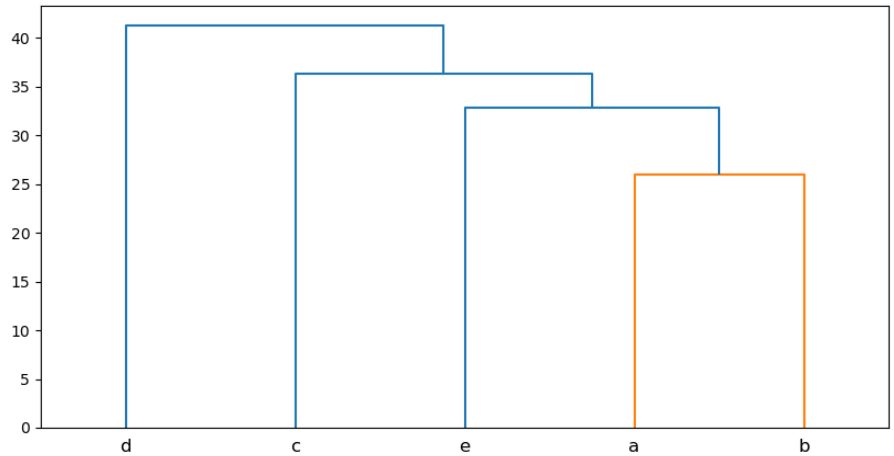

Centroid Linkage
Cluster B
Cluster A

Exemplo e Comparação Linkages

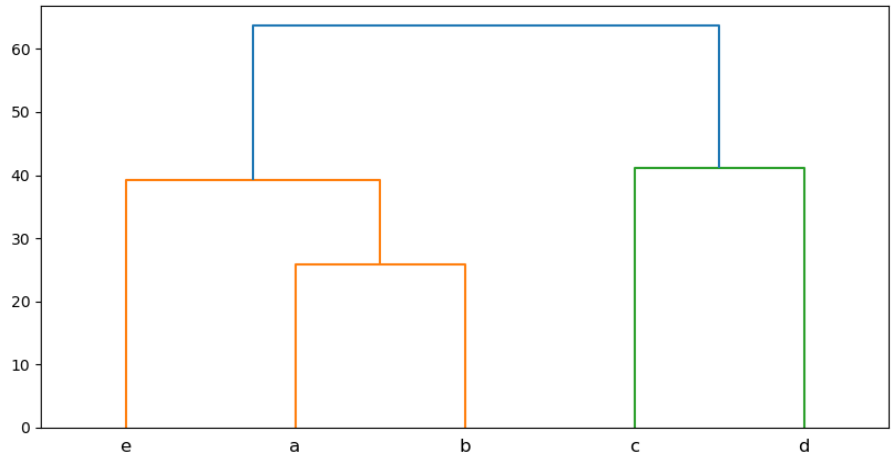
Vamos executar Single e Complete Linkage com a tabela de distâncias abaixo:

d(x,y)	**a**	**b**	**c**	**d**	**e**
a	0	17	21	31	23
b	17	0	30	34	21
c	21	30	0	28	39
d	31	34	28	0	43
e	23	21	39	43	0

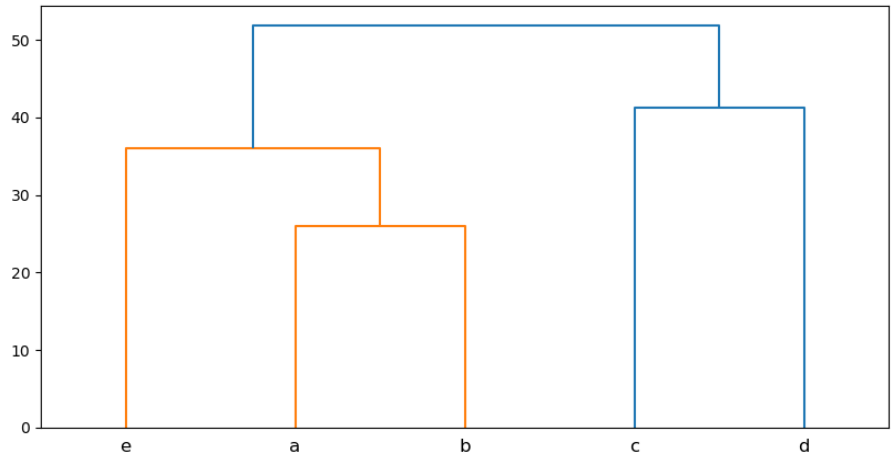
Exercício - Single-linkage



Exercício - Complete-linkage



Exercício - Average-linkage



Bisecting K-Means

1 Agrupamento Hierárquico

2 Linkage Family

3 Comparação e Exercício

4 Bisecting K-Means

Um algoritmo divisivo

- Pelo nome já temos uma ideia do funcionamento desse algoritmo

Um algoritmo divisivo

- Pelo nome já temos uma ideia do funcionamento desse algoritmo
- Segue os seguintes passos:
  1. Começando com um único grupo, que será escolhido na etapa 2.1
  2. Enquanto a quantidade de grupos for menor que a quantidade de amostras:
     1. Aplicar 2-Means no grupo escolhido
     2. Escolher um dos grupos, aquele com a maior soma dos erros quadráticos

Discussão

- Não podemos usar a mesma matriz do exercício anterior, o *Bisecting K-Means* precisa das posições das amostras para fazer seus cálculos
- Ele sofre dos mesmos problemas do **k-means** em relação à seleção de centróides
- Tenderá a ter grupos globulares
- Não sofre de *chainning effect*