

Pontifícia Universidade Católica de Campinas
Escola Politécnica

Medidas Descritivas

Análise e Visualização de Dados

Fernando H Carvalho Silva
E-mail: fernando.henrique@puc-campinas.edu.br

Agosto de 2025

Existem três tipos fundamentais de medidas estatísticas: medidas de tendência, medidas de dispersão e medidas de posição relativa.

As **medidas de tendência central** mostram o valor representativo em torno do qual os dados tendem a agrupar-se, dão o ponto central em torno do qual os dados se distribuem.

As **medidas de dispersão** mostram o grau de afastamento dos valores observados em relação ao ponto central da distribuição dos dados.

As **medidas de posição relativa** mostram pontos de corte na distribuição relativa dos dados da amostra.

MÉDIA ARITMÉTICA SIMPLES

- De modo geral, é a mais importante de todas as medidas de tendência central.
- A média de uma amostra é denotada por $\bar{x}$ e a média de uma população é denotada por μ.
- Seja $(x_1, x_2, x_3, \ldots, x_4)$ uma amostra de n observações de certa variável X. Para calcular a média de um conjunto de valores é necessário somar todos os valores obtidos e dividir por n que representa o tamanho da amostra.
- Em notação matemática o cálculo da média é obtida por:

$$\bar{x} = \frac{\sum_{i=1}^{n} x_i}{n} = \frac{x_1 + x_2 + \ldots + x_n}{n}$$

MÉDIA ARITMÉTICA SIMPLES - Exemplo

Um pesquisador interessado em avaliar o nível de ruído em um determinado cruzamento movimentado da cidade, mediu o nível de ruído (em decibéis) durante 18 dias. Os dados encontram-se abaixo:

85	92	95	98	99	101	103	105	107
110	112	114	117	120	120	122	125	127

MÉDIA ARITMÉTICA SIMPLES - Exemplo

85	92	95	98	99	101	103	105	107
110	112	114	117	120	120	122	125	127

Neste conjunto de dados n = 18 e utilizando a fórmula da média encontramos:

$$\bar{x} = \frac{85 + 92 + \cdots + 125 + 127}{18} = 108{,}44$$

Portanto, podemos observar que o nível médio de ruído no cruzamento estudado foi de 108,44 decibéis.

MEDIANA

- É o valor que divide o conjunto de dados ao meio, deixando 50% menores valores de um lado e os 50% maiores valores do outro lado.
- É denotada por $\tilde{x}$.
- Para calcular a mediana é necessário que o conjunto de dados esteja organizado em ordem crescente.
- Se n é ímpar, a mediana é dada pelo valor que ocupa a posição $\frac{n+1}{2}$.
- Se n é par, a mediana será a média dos valores que ocupam as posições $\frac{n}{2}$ e $\frac{n+2}{2}$

MEDIANA – Exemplo 1

Voltando ao exemplo anterior, podemos observar que os dados já encontram-se dispostos em ordem crescente. Como o tamanho da amostra é par (n=18), a mediana é calculada fazendo-se uma média dos valores que encontram-se localizados nas posições $\frac{n}{2} = 9° \, elemento$ e $\frac{n+2}{2}$ = 10° elemento.

85	92	95	98	99	101	103	105	107
110	112	114	117	120	120	122	125	127

Ou seja, $\tilde{x} = \frac{107+110}{2} = 108{,}5$

Podemos concluir que em metade dos dias analisados o nível de ruído foi inferior ou igual a 108,5 decibéis.

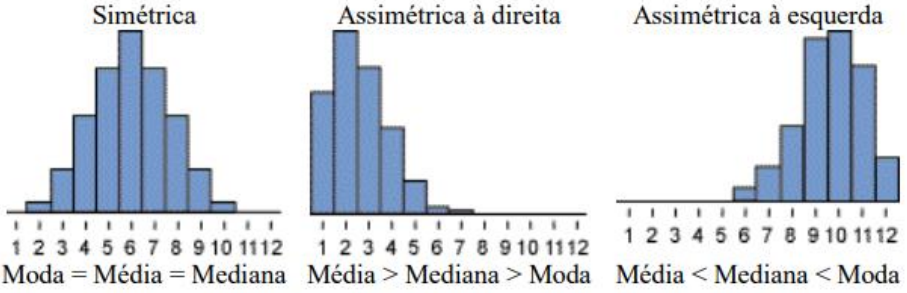
MODA

- Dado um conjunto de valores, a Moda (Mo) desses valores será aquele que se repetir o maior número de vezes.
- Podemos ter uma amostra que não tem moda que é chamada de amodal, também pode ocorrer duas modas (chamadas bimodal) ou mais de duas modas (chamada multimodal).
- No exemplo 1, a moda é 120.

- Importante: A moda é a única medida de tendência central que pode ser usada para descrever dados qualitativos.

Forma de uma distribuição

A distribuição dos dados é assimétrica quando estende-se mais para um lado do que para o outro. Nesses casos, a média tende a deslocar-se para o lado da cauda mais longa.



A média sempre irá cair na direção em que a distribuição for assimétrica. Por exemplo, quando uma distribuição for assimétrica à esquerda, a média estará à esquerda da mediana.

Qual é a melhor medida de tendência central?

Não há regra fixa para se escolher tal ou qual medida de tendência central. Em cada situação específica o problema deve ser analisado:

- A média aritmética é a medida sintetizadora mais adequada quando não há valores erráticos ou discrepantes (outliers).

- A mediana deve ser usada sempre que possível como medida representativa de distribuições fortemente assimétricas, como distribuição de renda, etc.

Medidas de variabilidade

Quase nunca uma única medida é suficiente para descrever de modo satisfatório um conjunto de dados. Tomemos com exemplo o caso da média aritmética, que é uma medida de tendência central largamente empregada, e consideremos os dois conjuntos de observações:

$$A = \{25\ 28\ 31\ 34\ 37\} \qquad B = \{17\ 23\ 30\ 39\ 46\}$$

Ambos têm a mesma média, 31. No entendo, pode-se perceber intuitivamente que o conjunto B tem maior dispersão do que o conjunto A.
É necessário estabelecer medidas que indiquem o grau de dispersão, ou variabilidade, em relação ao valor central.

AMPLITUDE

- A notação utilizada para representar a amplitude é: A.
- É definida como sendo a diferença entre o maior e o menor valor do conjunto de dados.
- A vantagem da amplitude é sua facilidade de cálculo, porém, tem a desvantagem de levar em conta apenas dois valores, desprezando todos os outros.

AMPLITUDE - Exemplo

Um pesquisador está interessado em avaliar o tempo (em segundos) que os consumidores demoram entre o início e a finalização de uma compra em um determinado site da Internet. Para isso, observou 12 consumidores escolhidos aleatoriamente no sistema. Os dados encontra-se abaixo:

71	73	73	74	74	75
76	77	77	79	81	83

A amplitude dos tempos é: A = 83-71 = 12 segundos.

VARIÂNCIA E DESVIO PADRÃO

- A variância e o desvio padrão são medidas de variação bastante úteis e largamente utilizadas.
- A dispersão (variabilidade) de um conjunto de dados é pequena se os dados estão concentrados em torno da média, e é grande se os dados estão muito afastados da média.
- A variância e o desvio padrão medem a variação do conjunto de dados em torno da média.
- As notações utilizada para representarmos as duas medidas são:

Medidas	População	Amostra
Variância	σ^2	s^2
Desvio padrão	σ	s

VARIÂNCIA E DESVIO PADRÃO

Como a variância e o desvio padrão levem em consideração todos os valores da amostra e também da média amostral, seu cálculo é mais demorado.

$$s^2 = \frac{\sum_{i=1}^{n}(x_i - \bar{x})^2}{n-1} \qquad \text{ou} \qquad s^2 = \frac{\left(\sum_{i=1}^{n} x_i^2\right) - \left[\frac{\left(\sum_{i=1}^{n} x_i\right)^2}{n}\right]}{n-1}$$

VARIÂNCIA E DESVIO PADRÃO

É possível perceber que a unidade de medida da variância equivale à unidade de medida dos dados ao quadrado. Dessa maneira, é mais comum trabalharmos com a raiz quadrada da variância, ou seja, com o *desvio padrão.*

Para o exemplo anterior vamos calcular a variância e o desvio padrão.

VARIÂNCIA E DESVIO PADRÃO- Exemplo

Utilizando a primeira fórmula:

O tempo médio é de 76,08 segundos.
A variância é:

$$s^2 = \frac{(71-76{,}08)^2 + (73-76{,}08)^2 + \ldots + (81-76{,}08)^2 + (83-76{,}08)^2}{12-1} = 12{,}447$$

O desvio padrão é:

$$s = \sqrt{12{,}447} = 3{,}528 \ \ segundos$$

VARIÂNCIA E DESVIO PADRÃO- Exemplo

Utilizando a segunda fórmula:

$$\sum x_i = 71 + 73 + \ldots + 81 + 83 = 913.$$

$$\sum x_i^2 = 71^2 + 73^2 + \ldots + 81^2 + 83^2 = 69601$$

A variância é: $s^2 = \dfrac{(69601) - \left[\dfrac{(913)^2}{12}\right]}{12-1} = 12{,}447.$

O desvio padrão é: $s = \sqrt{12{,}447} = 3{,}528$ *segundos*

Medidas de variabilidade

- Ao compararmos os desvios padrões de vários conjunto de dados, podemos avaliar quais se distribuem de forma mais ou menos dispersa.
- O desvio padrão será sempre não negativo e será tão maior quanto mais disperso forem os valores observados.

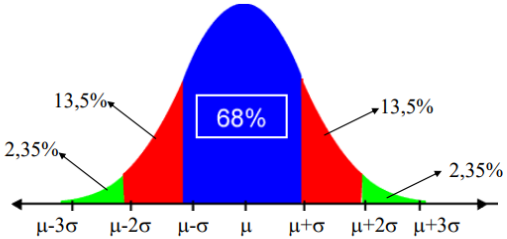
A tabela abaixo mostra o desvio padrão das notas de três turmas de alunos:

Turma	Nº de alunos	Média	Desvio padrão
A	8	6,00	1,31
B	8	6,00	3,51
C	7	6,00	2,69

Os alunos das três tenderam a ter notas em torno de seis. Pelos desvios padrões concluímos que os alunos da turma A obtiveram notas relativamente próximas umas das outras, quando comparados aos alunos das outras turmas. Por outro lado, as notas dos alunos da turma B foram as que se apresentaram mais heterogêneas.

INTERPRETAÇÃO PARA O DESVIO PADRÃO

Para conjuntos de dados com distribuição simétrica (onde o valor da média é igual ao da mediana) pode-se dizer que:



- Cerca de 68% dos dados estão a até 1 desvio padrão da média.
- Cerca de 95% dos dados estão a até 2 desvios padrão da média.
- Cerca de 99,7% dos dados estão a até 3 desvios padrão da média.

Assim como a mediana divide os dados em duas partes iguais, os três quartis, denotados por Q_1, Q_2 e Q_3, dividem as observações ordenadas em quatro partes aproximadamente iguais, ou seja, há cerca de 25% dos dados em cada grupo.

Analogamente, há nove decis, denotados por $D_1, D_2, \ldots, D_9$, que dividem os dados em 10 grupos com cerca de 10% dos dados em cada grupo.

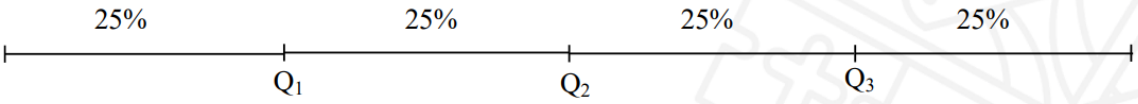
Há finalmente 99 percentis, que dividem os dados em 100 grupos com cerca de 1% dos dados em cada grupo.

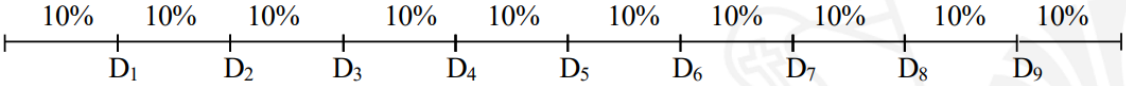
Para o cálculo de quartis, decis e percentis, primeiramente, é necessário que os dados estejam organizados em ordem crescente.

Tabela de correspondência entre os quartis, decis e percentis:

Quartil	Decil	Percentil
Q_1	$D_{2,5}$	P_{25}
Q_2	D_5	P_{50}
Q_3	$D_{7,5}$	P_{75}

Medidas de Posição Relativa







Cálculo do Percentil

1. Ordenar os dados do menor para o maior (ordem crescente);
2. Calcular a posição ocupada pelo percentil (P_k) por meio da seguinte fórmula:

$$L = \left(\frac{k}{100}\right).n$$

onde, n é o tamanho da amostra, k é o percentil que se deseja calcular e L é a posição do percentil na amostra.

Cálculo do Percentil

Se o valor de L é um número inteiro: o percentil P_k será obtido pela média entre os valores que ocupam as posições L e L+1.

Se o valor de L é um número decimal: devemos arredondar o valor de L para o maior inteiro mais próximo, aí sim o percentil P_k será obtido pelo valor que ocupa a posição L já arredondada.

Exemplo 1

Um pesquisador está interessado em avaliar o tempo (em segundos) que os consumidores demoram entre o início e a finalização de uma compra em um determinado site na Internet. Para isso, observou 12 consumidores escolhidos aleatoriamente no sistema. Os dados encontram-se abaixo:

71	73	73	74	74	75
76	77	77	79	81	83

A) Calcule o 3° Quartil:

Sabemos que o 3° quartil corresponde ao percentil 75. Dessa forma temos que a posição do 3° quartil na amostra é:

$$L = \left(\frac{k}{100}\right).n = \left(\frac{75}{100}\right).12 = 9° \, posição$$

Como a posição obtido (L) é inteira, para obtermos o 3° quartil é necessário calcular a média entre os valores que ocupam a 9° e a 10° posições.

Exemplo 1

Voltando aos dados da amostra temos que a 9°e a 10° posições correspondem aos valores:

71	73	73	74	74	75
76	77	77	79	81	83

O 3° quartil será a média entre eles = $Q_3 = P_{75} = \frac{77+79}{2} = 78$.

Aproximadamente 75% dos consumidores demoram até 78 segundos entre o início e a finalização da compra.

B. Calcule o 4° Decil:

Sabemos que o 4° decil corresponde ao percentil 40. Dessa forma, a posição do 4° decil na amostra é:

$$L = \left(\frac{k}{100}\right).n = \left(\frac{40}{100}\right).12 = 4{,}8\ (arredondar\ para\ cima)$$

Como a posição obtida (L) é decimal, para obtermos o 4° decil devemos encontrar o valor que ocupa a 5° posição da amostra.

Exemplo 1

Voltando aos dados da amostra temos que a 5° posição corresponde ao valor:

71	73	73	74	74	75
76	77	77	79	81	83

O 4° decil será: $D_4 = P_{40} = 74$.
Aproximadamente 40% dos consumidores demoram até 74 segundos entre o início e a finalização da compra.

Exercícios 1

Agora é com você!

- 10% dos consumidores mais rápidos demoram, no máximo, quantos segundos entre o início e a finalização da compra? Resposta: 73.

- 20% dos consumidores demoram, no mínimo, quantos segundos entre o início e a finalização da compra? Reposta: 79.

Escore Z ou escore padronizado

Sabe-se que o QI médio é aquele igual a 100. A partir daí sabe-se que um QI igual a 102 é bastante comum, enquanto um QI 170 é bastante raro. Esse QI de 102 é bastante comum porque está próximo da média, mas o QI de 170 é raro porque está bem acima de 100, que é a média.

O objetivo de se calcular o escore z é expressar em unidades de desvio padrão quanto um determinado número está distante da média.

Escore Z ou escore padronizado

Para cálculo do escore z é necessário conhecer a média e o desvio padrão.

$$\textbf{Escore z} = \frac{x - \bar{x}}{s}$$

Para a turma de GTI, as notas dos alunos na 1° avaliação (no valor de 20 pontos) encontram-se a seguir:

2	3	4	5	6	14
15	16	17	18	19	

Escore Z ou escore padronizado

2	3	4	5	6	14
15	16	17	18	19	

Para essa amostra calculou-se a média e o desvio padrão:

$$\bar{x} = 10{,}8$$
$$s = 6{,}7$$

O escore Z de um aluno que tirou 15 pontos na prova é:

$$Escore\ Z = \frac{x - \bar{x}}{s} = \frac{15 - 10{,}8}{6{,}7} = 0{,}63$$

Ou seja, esse aluno tirou uma nota que está situada a 0,63 desvios padrão acima da média.

Escore Z ou escore padronizado

O escore Z de um aluno que tirou 4 pontos na prova é:

$$Escore\ Z = \frac{x - \bar{x}}{s} = \frac{4 - 10{,}8}{6{,}7} = -1{,}01$$

Ou seja, esse aluno tirou uma nota que está situada a 1,01 desvios padrão abaixo da média.

Escore Z ou escore padronizado

A importância dos escores z na estatística reside no fato de que eles permitem distinguir entre valores usuais e valores raros, ou incomuns (outliers). Consideramos usuais os valores cujos escores padronizados estão entre –2,00 e 2,00, e incomuns os valores com escore z inferior a –2,00 ou superior a 2,00. Veja o esquema a seguir:

